Machine Learning Final Project

題目: Cyber Security Attack Defender
隊名: NTU_b03901057_XXXYYY 什麼鬼都可以吧
隊員:

b03901057 詹晉誠
b03901138 張晏祐
b03902035 黃兆緯

工作分配:

詹晉誠：Task1、Task3
張晏祐：Task1、Task3
黃兆緯：Task1、report

---

1. Preprocessing and Feature Engineering

1) Dataset
在做任何處理之前，首先檢查 dataset 的基本資料：

	Training set	Testing set
出處	DARPA'98 IDS evaluation program	
size	4408587	606779
# of features	41	
# of continuous features	34	
# of discrete features	7	

這個 task 跟 hw2 的 0/1 分類問題很相似，因此我們想用類似的方法來進行這個 task，這兩個問題的差別有：

(a) hw2 資料裡的 feature 都是連續的，這次有部份離散 feature。
(b) hw2 是 0/1 分類問題，這次是多分類問題（5 個分類、40 種攻擊）。
(c) hw2 的資料集小很多，training set 只有 4000 筆，而這次有四百萬筆。

為了用類似 hw2 的方法來進行，在前處理時需要將離散 feature 轉為連續的（有數字大小意義的）。使用的 model 需要可以處理多分類問題（one-versus-rest 或 multinomial）。另外，由於資料集較大，model 的訓練時間是需要被考慮的因素。檢查完 dataset 的基本資料後，我們開始想辦法處理上述的三個問題。

2) Discrete features

Feature	Description	Type	Feature	Description	Type
1. duration	Duration of the connection.	Cont.	**22. is guest login**	1 if the login is a "guest" login; 0 otherwise	Disc.
2. protocol type	Connection protocol (e.g. tcp, udp)	Disc.	**23. Count**	number of connections to the same host as the current connection in the past two seconds	Cont.
3. service	Destination service (e.g. telnet, ftp)	Disc.	**24. srv count**	number of connections to the same service as the current connection in the past two seconds	Cont.
4. flag	Status flag of the connection	Disc.	**25. serror rate**	% of connections that have "SYN" errors	Cont.
5. source bytes	Bytes sent from source to destination	Cont.	**26. srv serror rate**	% of connections that have "SYN" errors	Cont.
6. destination bytes	Bytes sent from destination to source	Cont.	**27. rerror rate**	% of connections that have "REJ" errors	Cont.
7. land	1 if connection is from/to the same host/port; 0 otherwise	Disc.	**28. srv rerror rate**	% of connections that have "REJ" errors	Cont.
8. wrong fragment	number of wrong fragments	Cont.	**29. same srv rate**	% of connections to the same service	Cont.
9. urgent	number of urgent packets	Cont.	**30. diff srv rate**	% of connections to different services	Cont.
10. hot	number of "hot" indicators	Cont.	**31. srv diff host rate**	% of connections to different hosts	Cont.
11. failed logins	number of failed logins	Cont.	**32. dst host count**	count of connections having the same destination host	Cont.
12. logged in	1 if successfully logged in; 0 otherwise	Disc.	**33. dst host srv count**	count of connections having the same destination host and using the same service	Cont.
13. # compromised	number of "compromised" conditions	Cont.	**34. dst host same srv rate**	% of connections having the same destination host and using the same service	Cont.
14. root shell	1 if root shell is obtained; 0 otherwise	Cont.	**35. dst host diff srv rate**	% of different services on the current host	Cont.
15. su attempted	1 if "su root" command attempted; 0 otherwise	Cont.	**36. dst host same src port rate**	% of connections to the current host having the same src port	Cont.
16. # root	number of "root" accesses	Cont.	**37. dst host srv diff host rate**	% of connections to the same service coming from different hosts	Cont.
17. # file creations	number of file creation operations	Cont.	**38. dst host serror rate**	% of connections to the current host that have an S0 error	Cont.
18. # shells	number of shell prompts	Cont.	**39. dst host srv serror rate**	% of connections to the current host and specified service that have an S0 error	Cont.
19. # access files	number of operations on access control files	Cont.	**40. dst host rerror rate**	% of connections to the current host that have an RST error	Cont.
20. # outbound cmds	number of outbound commands in an ftp session	Cont.	**41. dst host srv rerror rate**	% of connections to the current host and specified service that have an RST error	Cont.
21. is hot login	1 if the login belongs to the "hot" list; 0 otherwise	Disc.			

根據投影片上的 feature 介紹，總共 41 個 feature 中，有 7 個 discrete feature，分別是：protocol type、service、flag、land、logged in、is hot login、is guest login。應用一些網路攻擊的知識可以知道，這些 discrete feature 對於判斷攻擊類型有很大的作用。例如 pod(Ping of Death)攻擊是使用 ping，因此 protocol type 是 ICMP。

為了讓這些 discrete feature 變為具有數值意義的 feature，我們使用的是 one-hot encoding，將每個種類變為一個維度，該維度僅有 0/1 兩種可能，0 代表原始資料並不是這個種類，相反地 1 代表原始資料是這個種類。例如 protocol type 有 icmp、tcp、udp 三種種類，則 encoding 舉例如下：

原始資料	Encoded
icmp	(1, 0, 0)
udp	(0, 0, 1)
abc	(0, 0, 0)

使用 one-hot encoding 後，discrete features 都被轉為具有數值意義的 feature（但這些新 feature 其實比較適合 decision-based 的模型，因為 0/1 的意義並不明確）。最後將原本的 41 維資料轉為 122 維資料，維度變為三倍。因此訓練時間變得更久，之後選擇模型要更加考慮訓練時間。

3) 多分類問題

從 0/1 分類問題變為 5 分類甚至 40 分類的多分類問題，其實並不是很大的問題，很多套件提供的模型都支援多分類問題（例如我們使用的 scikit-learn），即使不支援多分類問題，也可以針對每個分類訓練一個 0/1 分類模型，再對這幾個模型的輸出進行組合即可。

4) Dataset Size

這個 task 的 training set 有 440 萬筆，是 hw2 的 1100 倍，這造成某些 model 的訓練時間太久，會不方便進行測試。

首先我們發現有一些 data 是完全一模一樣的，排除掉相同的 data 可以減少資料量，但這會導致 training set 的分布改變（完全相同的 data 也許是增加權重資訊），因此我們並沒有排除相同的 data。

5) Feature Extraction

利用 one-hot encoding 後，變成 122 維的 data。首先我們考慮每個 feature 間的交互關係，可以加上兩兩相乘的 feature，但這樣一來每筆 data 就會超過 10000 維，遠遠超過我們能處理的大小，因此並不考慮這個方法。

利用 chi-square test 和相關係數來檢查 feature 和 label 的相關性。檢查的結果為除了特定幾個 feature 和 label 相關性特別高，其他 feature 和 label 的相關性都差不多，因此進行了下面兩個實驗：

(a) 只取相關性最高的幾個 feature

(b) 取所有 feature

最後實驗的結果為 (b) 較優，因此我們都取全部的 feature 來訓練。

2. Model Description

進行完資料前處理和 feature 選擇後，我們選定了幾種模型來做接下來的實驗。首先仿照 hw2 的作法，使用 Logistic Regression 和 DNN，另外，由於我們對 discrete features 做了 one-hot encoding，這樣的 feature 會比較適合 decision-based 的模型，因此選用 Random Forest 和 Gradient Boosting Decision Tree。

1) Simple models

包含 regression-based 的 Logistic Regression 和 DNN，以及 decision-based 的 Random Forest 和 Gradient Boosting Decision Tree。這些模型在 scikit-learn 中都有實作，我們都是使用 scikit-learn 的模型。

(a) Logistic Regression

課堂上有介紹過的模型，輸出$y = sign\big(sigmoid(w^T x + b)\big)$，可以用 gradient descent 來接近最佳解。

(b) DNN

多層類神經網路，最基本的 DNN 就是 Multi-layer perceptron，也可以使用 gradient descent 來接近最佳解，但隨著初始化不同會有不同的走向。最後一層使用 softmax 當作激活函數就可以解多分類問題。

(c) Random Forest

使用 decision-based 的 Decision Tree 當作基本的小模型，利用 bootstrap（取後放回的抽樣）的技巧來給予每棵樹不同的 training data，再將這些分類能力比較弱的樹作 bagging ensemble，得到最後的結果。

(d) Gradient Boosting Decision Tree

Boosting 是一種「改變錯誤」的技巧，每次訓練完一個小模型後，將這個模型分類錯誤的 data 的權重調高，再進行下一次訓練，如此一來可以將錯誤調整回來。而 Gradient Boosting 則是使用 Boosting 概念的一種優化方法，和 Linear Regression 的 gradient descent 很像，但 Gradient Boosting 是計算先前模型的 loss function 的 gradient，往 gradient 的反方向走。

Gradient Boosting Decision Tree 就是使用 Decision Tree 作為 base model 的模型。

Simple model 的整體架構非常簡單，模型示意圖如下：

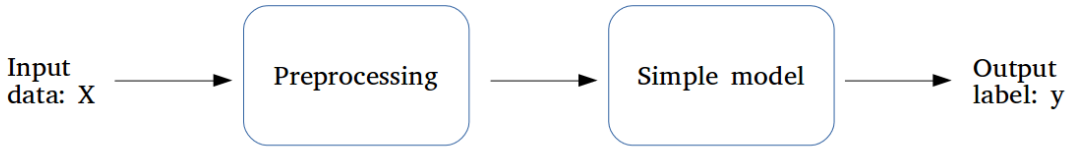

2) 40 Labels classifier

由於原本的 training data 的 label 是 40 種，然後再對應到 normal 和四種攻擊，因此我們嘗試不直接把 training data 對應成 5 種分類，而是直接訓練一個 40 分類的分類器，再將四種攻擊對應到的分類的機率平均起來，最後輸出成 5 種分類，模型示意圖更改如下：

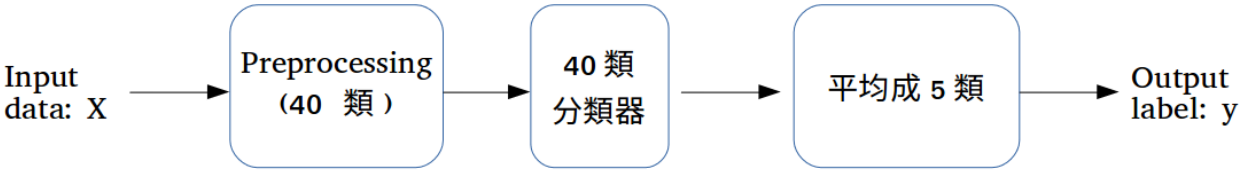

3) Altered models

由於這個 task 的 training set 和 testing set 分布相當不同，因此適當的矯正模型的輸出分布可以使預測 testing set 的效果變好（我們可以透過 kaggle 知道 testing set 的分布）。Altered model 就是在 simple model 的基礎上，對模型輸出的分布做調整，而我們做的調整有兩種：

(a) 將預測為 label 0 重新檢查

由於預測 label 0 的比例太高了，因此將 label 0 預測機率小於 1 的所有 data，改為預測機率第二大的 label，模型示意圖更改如下：

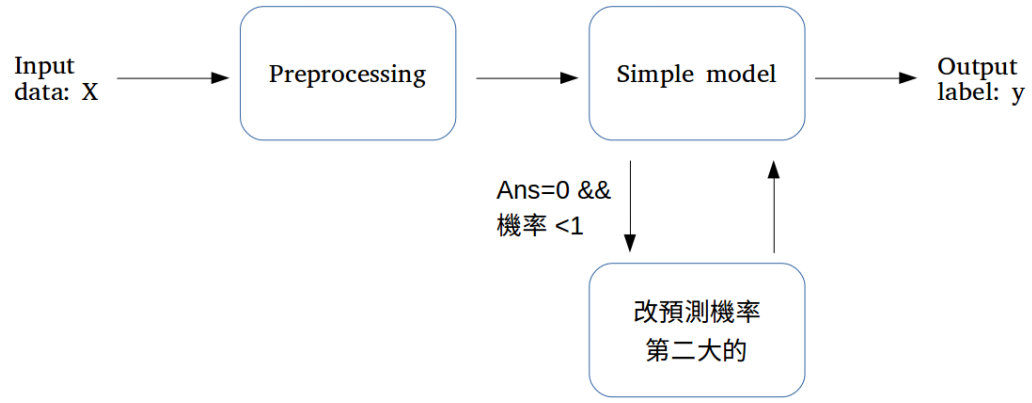

(b) 優先填滿分布差異較大的分類

在比較 training set 和 testing set 的分布差異時，我們發現 label 3 的分布差異最大，因此優先考慮 label 3，訓練一個 label 3 的 0/1 分類模型，先將這個模型預測機率最大的 data 標記為 label 3，剩下的 data 再給 simple model 預測得到剩下的 label，模型示意圖如下：

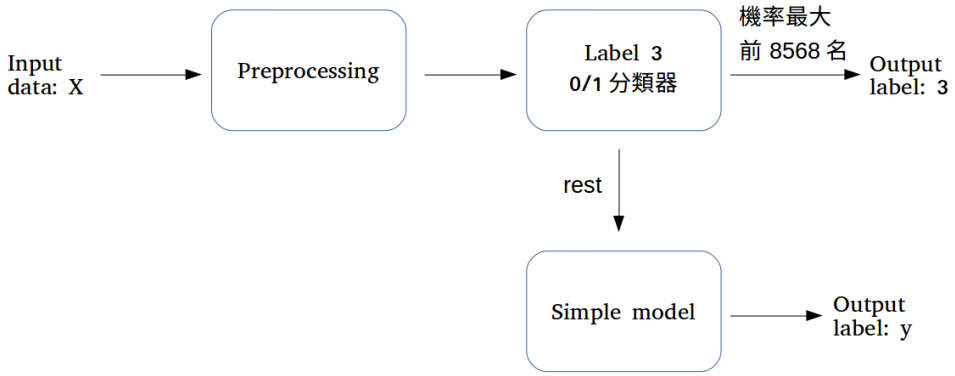

3. Experiments and Discussions

1) Model 比較

		CV/OOB score	Public score	Training time
Simple model	Logistic Regression			>12 hours
	DNN	0.9997	0.95702	10 mins
	Random Forest n=100	0.99999	0.95752	3 mins / 8 thread
	Random Forest n=1000	0.99999	0.96128	30 mins / 8 thread
	GBDT, n=100	0.99999	0.96265	6 hours / 1 thread
40 labels	Random Forest n=1000	0.99999	0.96038	1 hour / 8 thread
Altered model	2.(a)		0.96415	
	2.(b)		0.96895	

可以看到幾乎所有 model 的 CV/OOB score 都是 0.999 以上，這代表對於 training set 的分布來說，這些 model 都可以分類的很好。然而到了預測 testing set 時，分數就降到了 0.96 左右，被分布差異影響很大。

訓練時間的部份，Logistic Regression 訓練花費太久（超過 12 小時），因此之後都不使用；DNN 的訓練時間雖短，但性能太不穩定，因此也不使用；Random Forest 和 GBDT 的性能差不多，但訓練時間短很多，所以之後都經常使用 Random Forest 來做實驗。

Altered models 的部份，2(a)更改 label 0 答案的模型，對於 public score 有微小的進步，但是不能確定這個進步是運氣好或是實際有效；2(b)強調 label 3 的模型，public score 進步的幅度就比較明顯。

2) 分布差異

從先前的實驗中可以發現，training set 和 testing set 的分布有著很大的差異，而 testing set (public set) 的分布可以透過 kaggle 的分數來知道，因此我們用了 4 次 submission 來看 testing set 每個分類各佔了多少比例，得出來的數字如下：

	0	1	2	3	4
Training set	19.856	79.281	0.00098	0.023	0.839
Testing set	25.966	71.230	0.038	1.412	1.354
預測結果	29.858	68.840	0.00066	0.066	1.235

在 training set 和 testing set 的分布中，差最多筆的雖然是 label 0 和 label 1，但以比例來說差異最大的是 label 3。從預測結果來看也可以發現，label 3 幾乎沒辦法正確地預測出來，而 label 0 則是預測錯誤太多，錯誤的 4%中幾乎全部都是誤判為 label 0。

在這個分布差異下，我們想到了兩種模型來解決這個問題，也就是上面所提到的 Altered models。首先 2(a) 是想要將預測結果的 label 0 數量減少，而 2(b) 是想要將預測結果的 label 3 增加，Altered model 都是基於調整分布的想法建構的。

3) Altered models

使用 Altered model 來調整分布後，public score 都有上升，因此我們認為 Altered model 是有用的，以下簡單分析兩個模型

(a) 更改 label 0 答案 [2.(a)]

這個模型的 public score 是 0.96415，而原本的 simple model 是使用 Random Forest (n=1000)，所以原本的 public score 為 0.96128，大約有 0.3%的進步。進步幅度雖然小，但仔細檢查後發現，更改答案後 label 0 大約佔 26%，其中正確的有 24.9%，也就是說誤判為 label 0 的錯誤從原本有 4%，更改後剩下 1%，這是很大的進步，也證明這個模型是可行的，可惜即使判斷出哪些是誤判，還是很難重新判斷是哪種攻擊，因此這個模型的進步幅度並不大。

(b) 強調 label 3 [2.(b)]

這個模型的 public score 是 0.96895，而原本的 simple model 是使用 Random Forest (n=1000)，所以原本的 public score 為 0.96128，大約有 0.75%的進步，這個進

步幅度比起上一個模型來的明顯多了，原因我們推測是由於 label 3 的分布差異太大了，原本的 simple model 幾乎沒有能力分類出 label 3，要是能完美分類出 label 3，那麼就能有 1.4%的進步，因此現在 0.75%的進步是可以想像的。

4) Normalization

由於 training set 和 testing set 的連續性 feature 的大小不一定意義相同（時間不同可能會有差異），而且我們使用的是 decision-based 的模型，對於這種 scale 可能不同的因素很敏感，因此我們想要使用 normalization 來減少這種差別。

我們對 training set 和 testing set 分別做 feature-wise 的 normalization，接著一樣使用 simple model 來進行訓練，最後的結果如下：

		CV/OOB score	Public score
Simple model	Random Forest n=1000	0.99999	0.95028
	GBDT, n=100	0.99999	0.95296

這個結果並沒有達到我們的預期，因此實驗都沒有使用 normalization

5) 40 label classifier

由於原本的 training data 的 label 是 40 種，然後再對應到 normal 和四種攻擊，因此我們直接訓練一個 40 分類的分類器，再將預測出來的機率作平均得到 5 分類的結果。這樣的 model 的 public score 為 0.96038，略遜於原本的 simple model。我們推測原因為這 40 種 label 其實也是非常不平均，大部分集中在其中幾個 label，因此其他小 label 一樣難以預測，所以效果和原本的 5 分類問題非常接近，甚至稍微遜於原本的模型。

5. Reference

1) MIT Lincoln Lab. DARPA Intrusion Detection Evaluation
https://www.ll.mit.edu/ideval/docs/attackDB.html#pod

2) A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection, Anna L. Buczak and Erhan Guven, IEEE